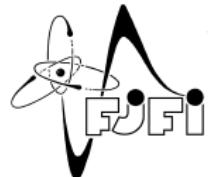




ČESKÉ VYSOKÉ UČENÍ TECHNICKÉ  
V PRAZE

Fakulta jaderná a fyzikálně inženýrská



# Detekce a sledování CCP v TIRF-SIM mikroskopii pomocí metod strojového učení

Závěrečný projekt k předmětu Strojové učení 2

Sabina Nešněrová

15. prosince 2025

# Obsah

1 Úloha

2 Použité metody

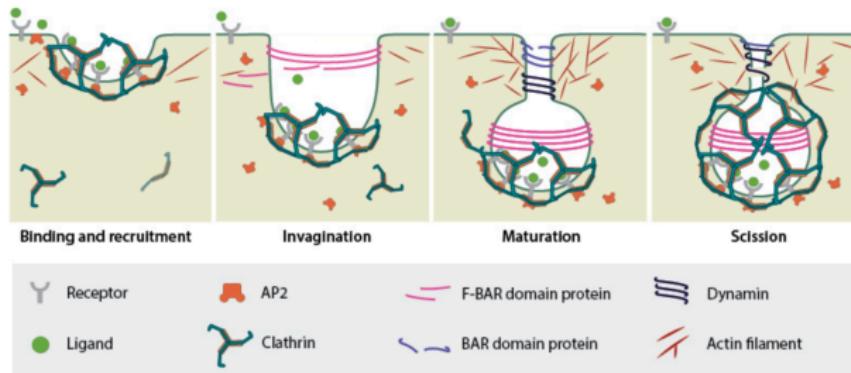
- Detekce
- Tracking

3 Výsledky

4 Shrnutí

# Úloha

- CCP = malé klatrinem potažené jamky na membráně buňky během endocytózy
- Vstup = TIRF-SIM data (osvětlená data) tvořená pomocí generátoru



Obrázek 1: Schéma průběhu endocytózy s CCP [1].

# Úloha

## Cíl

- Detektovat CCP.
- Sledovat jejich pohyb a změny v čase pomocí metod strojového učení.
- Vylepšení původních modelů pro zlepšení statistiky HOTA a přiblížení se/překonání referenční metody SOTA.

Model	SOTA	CNN	Morfological
HOTA	0.74	0.31	0.23
AssA	0.67	0.27	0.23
DetA	0.81	0.36	0.24

Tabulka 1: Výsledky referenční metody a původních metod.

# Vylepšení detektoru

- Byly použity tyto dva modely a následně porovnány:
- U-Net
  - přesná lokalizace malých objektů
  - robustní vůči šumu
- Res-U-Net
  - residiuální bloky - stabilnější trénink
  - nižší loss
  - rychlejší konvergence

# Vylepšení trackeru

- Kalmanův filtr
  - měl by lépe pracovat se šumem
- Norfair knihovna
  - komplexnější (měla by zvýšit AssA)
- Nearest-neighbor tracker
  - ponechán z původního souboru
- Optimalizace parametrů

# Parametry trénování

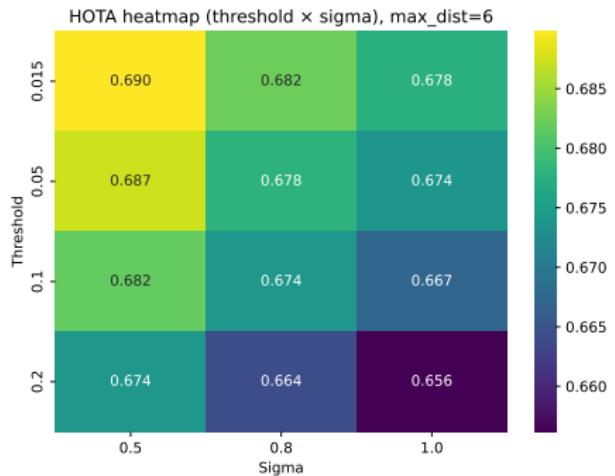
- Modely byly natrénovány v Google Colab (chyba).
- Pro oba modely byly použity stejné parametry pro trénování:

Velikost dat	Batch size	Počet epoch	Learning rate
4000	32	20	0.001

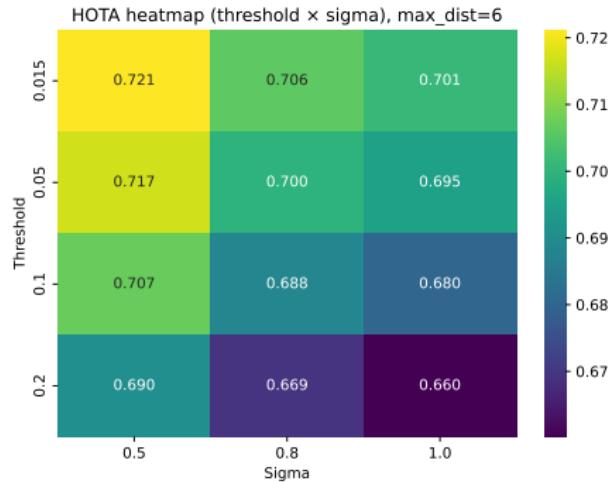
Tabulka 2: Parametry modelů

- Po natrénování proveden Grid-search pro ladění parametrů pro tracking.
- Nejlepší výsledky pro velmi malý threshold a sigma.

# Grid search pro parametry



Obrázek 2: U-Net.



Obrázek 3: Res-U-Net .

# Výsledky

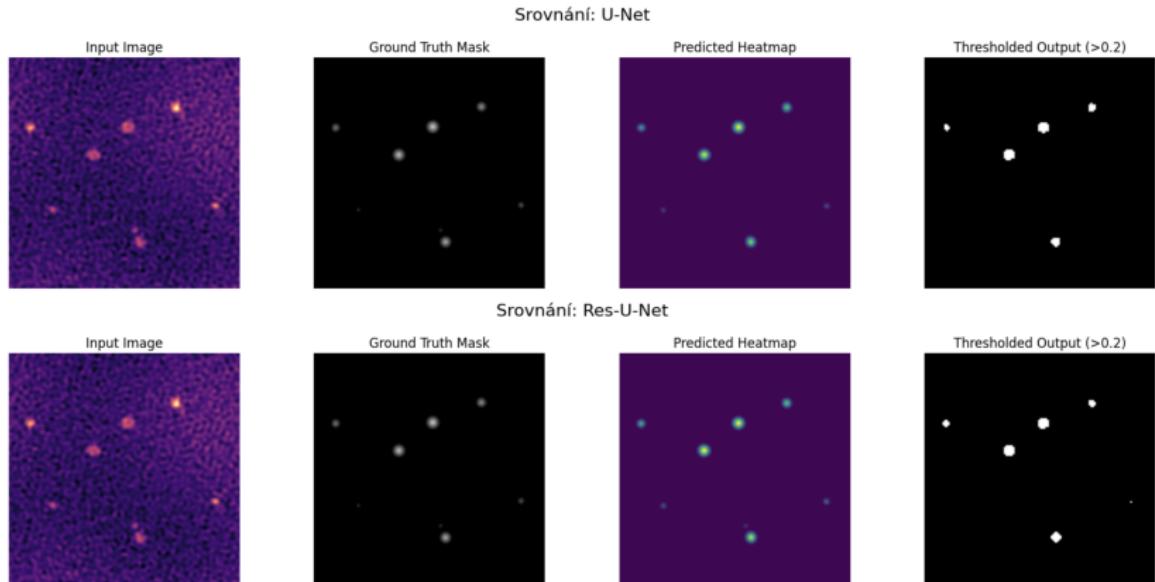
Model	HOTA	AssA	DetA	Threshold	sigma	max_dist
U-Net	0.69	0.61	0.78	0.015	0.5	6
Res-U-Net	0.72	0.65	0.81	0.05	0.5	6

Tabulka 3: Nejlepší modely NN tracker.

Model	HOTA	AssA	DetA	Threshold	sigma	max_dist
U-Net	0.59	0.48	0.72	0.015	0.5	6
Res-U-Net	0.60	0.52	0.70	0.2	1	6

Tabulka 4: Nejlepší modely s Kalmanovým filtrem.

# Porovnání na syntetickém datasetu



Obrázek 4: Porovnání U-Net a Res-U-Net s NN.

# Precision a recall

- Byly spočteny precision a recall.
- Pro všechny modely vychází vysoký recall a velmi nízká precision.
- Nejspíš souvisí s kombinací nízkých parametrů.
- Nízký threshold způsobil velké množství šumu.

Model	Precision	Recall
U-Net	0.107	0.786
Res-U-Net	0.103	0.831

Tabulka 5: Precision a recall.

# Interpretace

- Norfair tracker dosahuje velmi špatných výsledků v porovnání s ostatními bez ohledu na použitou metriku.
- Kalmanův filtr se ukázal jako neúčinný v porovnání s NN trackerem.
- Res-U-Net v kombinaci s NN trackerem výrazně zlepšil HOTA a liší se pouze o 0.02 od SOTA metody.
- U Res-U-Net se dokonce podařilo dospět ke stejnému DetA jako má metoda SOTA.
- Nejlepší výsledky při malém  $\text{max\_dist} = 6$ ,  $\text{threshold} = 0.015$  a  $\sigma = 0.5$ .
- Velmi nízké precision bylo nejspíše způsobeno nízkými hodnotami parametrů.

# Shrnutí

- Byl nalezen velmi dobrý model s HOTA 0.72, který se liší pouze o 0.02 od referenční metody.
- Nejlepší kombinace byla **Res-U-Net** (kvalitní DetA) spolu s **Nearest-Neighbor** (stabilní AssA).
- Příště by bylo vhodné zvolit jinou loss funkci (pro vyšší precision), případně pokročilejší model (U-Net++).

**Děkuji za pozornost!**

---

[1] Mechanobiology Institute, National University of Singapore. How does invagination and maturation of the clathrin-coated vesicle occur?